多通道远场语音前端

技术总结 / 1 问题、方法与主评测

目标：把增强与识别放到同一张可核验的结果表中

输入含混响、点源干扰与扩散噪声的多通道语音，输出单通道音频送入固定中文 ASR。同时报告直达参考 SI-SDR、PESQ-WB、STOI 和语料级 CER，保留效果退化的负结果。

数据与隔离

原始 AISHELL 测试划分 200 条、20 位说话人，4 麦线阵/6 麦圆阵，RT60 为 0.2/0.4/0.6 秒，多房间、距离与方向。训练 320 条、开发 80 条，各两次仿真，共 800 个样本；说话人与源噪声跨集合隔离。固定种子，验证源文件、分量加和、SNR/SIR、前缀与产物哈希；不声称验证完整原始归档 MD5。

算法链路

多通道 STFT → DAS / 已知方向 MVDR / 掩码加权协方差 Souden MVDR → ISTFT → 固定 ASR。MVDR 解线性方程，对角加载为 1e-3 × 通道平均功率 + 1e-12；0.6 秒纯噪声前缀的完整窗估计噪声协方差。神经分支用参考通道 log-power、两层单向 GRU、83,137 参数，预测功率 IRM。CPU 训练 20 epoch，最佳开发轮次 19。

相同 200 条主测试的实测结果

前端	SI-SDR / dB	PESQ	STOI	CER
参考通道	-8.327	1.064	0.486	37.89%
DAS	-6.090	1.079	0.524	28.91%
Oracle MVDR	-2.501	1.102	0.616	17.27%
IRM MVDR	-1.978	1.177	0.602	17.41%
神经 MVDR	-6.176	1.074	0.512	33.37%
单通道补充模型	-4.871	1.164	0.500	51.85%

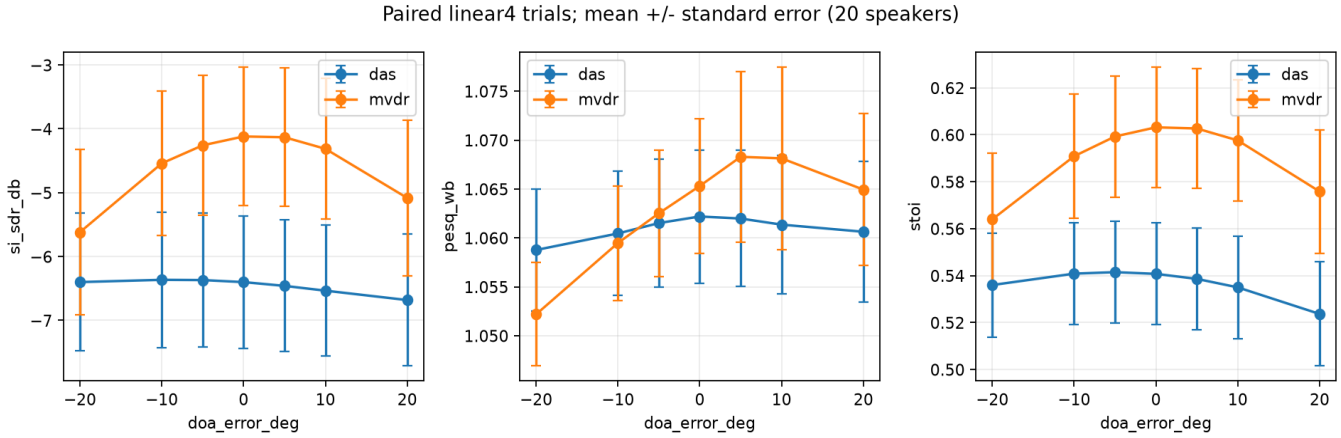
CER = 总编辑数 / 总参考字符数；1400 条解码均成功。干净 200 条 CER 为 2.66%，固定 50 条子集为 1.75%。ASR 为 SenseVoiceSmall int8 ONNX，固定中文、关闭 ITN、batch=1；控制 token 去除后使用统一 NFKC 文本规范化。

Oracle/IRM 读取额外真值，属于诊断参考，不能冒充可部署方案或逐指标数学上界。单通道对照为本轮补建，复用同一网络权重，未声称完整项目一 AEC/VAD 已完成。

结果边界与工程判断

配对消融：改变一个因素，保留同一声场

20 位测试说话人各一段最长 4 秒语音；所有阵列麦克风联合仿真，共享点噪声与扩散场。最大孔径固定 0.12 m，SNR=5 dB/SIR=0 dB 在虚拟中心校准，指标与导向也以中心为参考。完成 60 次场景仿真、1320 次有效评分；该协议与主测试的参考不同，不能直接混表。



图：4 麦线阵、RT60=0.4 秒；20 位说话人均值与标准误。

主要结论

1. 固定孔径下，线阵 MVDR 从 2 到 6 麦的 SI-SDR 从 -5.550 到 -3.851 dB；6 麦圆阵为 -1.202 dB。只说明本组场景的数量与几何收益，不能外推为所有方向的排名。

2. RT60 从 0.2 到 0.6 秒时，4 麦线阵 MVDR 的 SI-SDR 从 0.685 到 -6.376 dB。正负 20 度导向误差的对称平均损失：MVDR 1.231 dB，DAS 0.140 dB，显示自适应滤波的失配敏感性。

3. 神经 MVDR 未超过 DAS；单通道 SI-SDR/PESQ 改善却损害 CER。测试掩码图显示预测平滑且漏估语音高占比频点，但掩码偏差、协方差污染与 ASR 分布偏移仍需配对干预才能归因。已整理十个不同场景的文本与指标案例。

4. GCC-PHAT/SRP-PHAT/MUSIC 的目标方向 MAE 分别为 62.54/64.17/61.85 度。三类失败谱图显示峰值接近干扰方向；算法缺少目标身份信息，不能把主导源定位当成目标说话人定位。

复现证据与下一步

75 项测试、Ruff、两套环境依赖检查通过；特征、训练、增强与解码缓存绑定输入/代码/检查点哈希。完整命令见 docs/phase5_validation.md 与 docs/phase6_7_validation.md。当前只验证仿真数据，训练说话人覆盖较少、全句协方差为离线算法；优先扩大训练覆盖、验证目标保持策略及真实录音泛化。

来源：QwenAudio/SenseVoice 官方仓库 https://github.com/QwenAudio/SenseVoice；数据来源与条件详见 docs/data_sources.md。所有数字为本项目实际子集结果，不宣称复现官方全量精度。